



FACULTAD DE INGENIERIA

Universidad de Buenos Aires

Data Analytics para la estimación de la presión de yacimientos de petróleo

Director: Dr. Hernán Merlino (hmerlino@fi.uba.ar)

Co-directora: Dra. Gabriela Savioli (gsavioli@fi.uba.ar)

Integrantes

Nombre	Email	Padrón
Alan Valdevenito	avaldevenito@fi.uba.ar	107585
Franco Bragantini	fbragantini@fi.uba.ar	97190
Mateo Rico	mrico@fi.uba.ar	108127
Máximo Palopoli	mpalopoli@fi.uba.ar	108755

Índice

1. Aval del Director	1
2. Resumen	2
3. Palabras clave	3
4. Abstract	4
5. Keywords	5
6. Agradecimientos	6
7. Introducción	7
8. Estado del Arte	8
9. Problema detectado y/o faltante	10
10. Solución implementada	11
10.1. Arquitectura	11
10.1.1. Aplicación Web	11
10.1.2. Modelo de Machine Learning	12
11. Metodología aplicada	19
12. Herramientas externas utilizadas	20
13. Experimentación y/o validación	22
13.1. Evaluación y análisis comparativo de los modelos de machine learning	22
13.1.1. Modelo baseline	22
13.1.2. Random Forest	25
13.1.3. XGBoost	27
13.1.4. LSTM	30
13.1.5. Comparación final entre modelos	32
13.2. Validación de generalización multi-campo (leave-one-field-out)	34
14. Cronograma de las actividades realizadas	36

15. Riesgos materializados y Lecciones aprendidas	38
15.1. Riesgos materializados	38
15.1.1. Dependencia de datos de la industria	38
15.2. Lecciones aprendidas	38
15.2.1. Comprensión del dominio	38
15.2.2. Flexibilidad y adaptabilidad	38
15.2.3. Importancia de la validación continua	39
16. Impactos sociales y ambientales del proyecto	40
16.1. Impacto económico	40
16.2. Impacto social y ambiental	40
17. Trabajos futuros	41
18. Conclusiones	42
19. Aportes individuales	43
20. Referencias	44
21. Anexos	45

1 Aval del Director

En Buenos Aires a [día] de [mes] del año [año] se reúnen Dr. Hernán Merlino con los estudiantes de la carrera de Ingeniería en Informática: Franco Julián Bragantini, Máximo Palopoli, Mateo Julián Rico y Alan Valdevenito. El objetivo de la reunión es revisar el Informe Final del Trabajo Profesional de Ingeniería en Informática.

Luego de haber leído el informe del Trabajo Profesional **Data Analytics para la estimación de la presión de yacimientos de petróleo**, el Director del mismo, Dr. Hernán Merlino, declara que el mismo se corresponde con el trabajo realizado a lo largo del proyecto y avala el documento presentado como Informe Final, tanto en su completitud como en la claridad de redacción.

Firma y aclaración del director: [firma y aclaración]

Firmas y aclaraciones de los estudiantes: [firmas y aclaraciones]

2 Resumen

La estimación precisa de la presión en yacimientos de petróleo es un factor crítico para la gestión eficiente de la producción de hidrocarburos. Los métodos tradicionales, basados en la física de reservorios, presentan limitaciones frente al creciente volumen y complejidad de los datos disponibles. En este contexto, surge la necesidad de explorar nuevas herramientas que permitan realizar predicciones rápidas, robustas y escalables.

Este proyecto propone el desarrollo de un sistema basado en técnicas de *Data Analytics* y *Machine Learning*, orientado a la estimación de la presión de yacimientos. La solución integra un módulo de predicción que consume y procesa datos físicos del reservorio, entrenando modelos de regresión y aprendizaje profundo, junto con una interfaz web que facilita su uso por parte de ingenieros sin formación específica en ciencia de datos.

La metodología incluye el preprocesamiento y limpieza de datos, el diseño de *features*, la comparación de distintos algoritmos (como Random Forest, XGBoost, LSTM y PINNs) y la validación mediante métricas estándar de regresión, pruebas cruzadas y contrastes con metodologías convencionales (PTA, EBM). Asimismo, el proyecto sigue un enfoque ágil, con entregables iterativos y validación continua para garantizar la utilidad y confiabilidad del sistema.

El impacto esperado de esta propuesta radica en la optimización de la producción, la reducción de riesgos operativos y ambientales, y la provisión de una herramienta transparente y escalable que contribuya a la toma de decisiones en la industria energética.

3 Palabras clave

Yacimiento de petróleo, machine learning, estimación de presión, física de reservorio, recuperación secundaria.

4 Abstract

Accurate estimation of reservoir pressure is a key factor in the efficient management of hydrocarbon production. Traditional methods, based on reservoir physics, present limitations when dealing with the increasing volume and complexity of modern data. In this context, new approaches are required to provide fast, robust, and scalable predictions.

This project proposes the development of a system based on *Data Analytics* and *Machine Learning* techniques for reservoir pressure estimation. The solution integrates a prediction module that processes reservoir data and trains regression and deep learning models, along with a web interface designed for engineers without data science expertise.

The methodology includes data preprocessing and cleaning, feature engineering, evaluation of various algorithms (such as Random Forest, XGBoost, LSTM, and PINNs), and validation through standard regression metrics, cross-validation, and comparisons with conventional methods (PTA, EBM). The project follows an agile approach with iterative deliverables and continuous validation to ensure the system's utility and reliability.

The expected impact lies in production optimization, reduction of operational and environmental risks, and the delivery of a transparent and scalable tool that supports decision-making in the energy industry.

5 Keywords

Oil reservoir, machine learning, pressure estimation, reservoir physics, secondary recovery.

6 Agradecimientos

Texto de agradecimientos (sección opcional).

7 Introducción

La extracción de petróleo es un proceso que se lleva a cabo en formaciones subterráneas conocidas como yacimientos, donde el hidrocarburo, junto con otras sustancias como gas y agua, se encuentra almacenado en rocas porosas bajo condiciones de presión natural.

La gestión eficaz y la explotación económica de dichos yacimientos dependen fundamentalmente de una comprensión precisa de sus propiedades y comportamientos. Entre todos los parámetros que gobiernan la producción de hidrocarburos, la **presión** de yacimiento se erige como la variable más crítica.

Durante la fase inicial de la producción (recuperación primaria), la presión del reservorio es la fuerza motriz que empuja los fluidos desde la roca hasta la superficie [1]. Sin embargo, a medida que avanza la explotación del yacimiento, la presión disminuye progresivamente, por lo que para sostener la producción es necesario mantener o incrementar la presión mediante diferentes técnicas, entre las que destacan los métodos de **recuperación secundaria**, como la inyección de agua o gas.

En este contexto, la correcta estimación de la presión es la piedra angular de la ingeniería de yacimientos moderna, influyendo en cada decisión, desde la perforación del primer pozo exploratorio hasta el abandono final del campo.

En este documento presentamos un MVP de un sistema para estimar la presión de reservorios mediante un modelo predictivo de machine learning.

En las siguientes secciones se describe en mayor detalle el problema a resolver, la solución implementada, la metodología utilizada, el impacto del proyecto en la industria, la planificación del desarrollo y los mecanismos de validación del sistema.

8 Estado del Arte

Antes de la llegada del análisis de datos a gran escala, la ingeniería de yacimientos se basaba en dos pilares metodológicos: el Análisis de Transientes de Presión (PTA por sus siglas en inglés) y la Ecuación de Balance de Materiales (EBM).

El PTA es un enfoque dinámico que analiza la respuesta de la presión ante perturbaciones en el pozo. Incluye pruebas como drawdown y buildup, que permiten calcular parámetros locales como la permeabilidad promedio, el factor de daño (skin) y la presión promedio del área de drenaje. Su fortaleza radica en la alta resolución cerca del pozo, aunque con alcance espacial limitado.

La EBM, por su parte, aplica la conservación de la masa tratando al yacimiento como un “tanque” a volumen constante. Facilita la estimación de POES/GOES, la identificación del mecanismo de empuje y la predicción del comportamiento futuro. Su análisis suele apoyarse en métodos gráficos como P/Z vs. Gp, aunque asume homogeneidad en el yacimiento.

Ambos enfoques físicos, basados en los principios fundamentales de la física de fluidos en medios porosos, son complementarios y representan las herramientas clásicas que han permitido la caracterización y gestión de yacimientos durante décadas.

En la actualidad, la industria vive una transición hacia el paradigma basado en datos [5], impulsada por el crecimiento del volumen de datos proveniente de fuentes como adquisición sísmica, registros de perforación, sensores permanentes de pozos y laboratorios.

En este contexto, los métodos de data analytics y machine learning se posicionan como herramientas capaces de aprender directamente de los datos históricos. Estos modelos permiten:

- Optimizar la producción, identificando patrones ocultos y anticipando problemas como la irrupción de agua o arena.
- Mejorar la caracterización de yacimientos, integrando múltiples fuentes para generar modelos más precisos (ejemplo: incrementos del 30 % en la precisión de modelos geológicos reportados en la industria).
- Habilitar el mantenimiento predictivo, anticipando fallos en equipos críticos mediante análisis de datos de sensores.
- Reducir costos y riesgos, al mejorar la toma de decisiones en tiempo real y aumentar la seguridad operacional.

Entre los algoritmos más destacados se encuentran:

- **Redes Neuronales Artificiales (ANN):** sobresalientes en mapeos complejos, con resultados que superan correlaciones empíricas.

- **Random Forest y XGBoost:** robustos y eficientes para predicción de presiones críticas (p. ej., presión de burbuja, presión de poro).
- **Support Vector Regression (SVR):** eficaz en espacios de alta dimensionalidad, mejorando su precisión mediante optimización de hiperparámetros.
- **Redes LSTM:** especialistas en series temporales, ideales para pronósticos de producción y presión.

El avance más reciente es la integración de datos y física en enfoques híbridos. Los proxies de ML permiten generar predicciones en milisegundos tras ser entrenados con simulaciones numéricas, y las Redes Neuronales Informadas por la Física (PINNs) [6] incorporan ecuaciones diferenciales en su entrenamiento, garantizando consistencia física aun en ausencia de datos.

9 Problema detectado y/o faltante

Los métodos convencionales, aunque robustos y basados en principios físicos sólidos, muestran limitaciones significativas para manejar la escala y complejidad de los datos modernos:

- **Costo computacional:** La simulación numérica de yacimientos, el estándar de oro para el modelado predictivo, es un proceso extremadamente intensivo en términos computacionales. Una sola simulación de un modelo de alta resolución puede tardar horas o incluso días en completarse, lo que hace inviable la exploración exhaustiva de incertidumbres o la optimización en tiempo real [2].
- **Simplificación excesiva:** Los modelos analíticos, como la EBM, deben hacer suposiciones simplificadoras (por ejemplo, tratar el yacimiento como un tanque homogéneo) para ser matemáticamente tratables. Esto puede pasar por alto la heterogeneidad espacial compleja que a menudo controla el flujo de fluidos en la realidad [3].
- **Análisis manual y lento:** La interpretación de pruebas de pozo o la calibración de un simulador (ajuste histórico) son procesos que tradicionalmente han requerido un esfuerzo manual significativo por parte de ingenieros expertos, lo que los convierte en procesos lentos y potencialmente subjetivos [4].

En consecuencia, existe una brecha entre las necesidades actuales (predicciones rápidas, robustas y capaces de integrar múltiples fuentes de datos) y las capacidades de las metodologías tradicionales.

Esta brecha justifica la **exploración de nuevos enfoques** basados en Machine Learning, que permitan aprovechar datos históricos para generar estimaciones de presión más ágiles, transparentes y escalables.

10 Solución implementada

La solución implementada es una aplicación web que permite realizar estimaciones de la presión de un reservorio mediante un modelo de machine learning. El sistema toma como entrada un conjunto de datos cargados por el usuario y, a partir de ellos, genera una predicción de la presión del reservorio.

La información requerida comprende datos de producción, que corresponden a series temporales registradas a lo largo de la vida del reservorio, datos físicos del reservorio, e información termodinámica del petróleo del reservorio.

Una vez cargados los datos, el modelo procesa estas distintas fuentes de información para producir la estimación de presión. La aplicación presenta los resultados de forma visual, mediante gráficos que muestran tanto la presión estimada como la incertidumbre asociada a dicha estimación, permitiendo al usuario interpretar no solo el valor predicho sino también el grado de confianza del modelo.

10.1 Arquitectura

El sistema está compuesto una aplicación web (frontend y backend) y un modelo de machine learning.




Figura 1: Diagrama de arquitectura del sistema

En las siguientes secciones se detalla cada componente en profundidad.

10.1.1. Aplicación Web

El sistema está compuesto por una arquitectura cliente-servidor, donde el frontend permite la interacción con el usuario y el backend se encarga del procesamiento de datos, autenticación y ejecución del modelo predictivo.

La aplicación permite a los usuarios registrarse e iniciar sesión, gestionando el acceso a las funcionalidades mediante autenticación. Una vez dentro del sistema, el usuario puede cargar diferentes tipos de datos necesarios para la estimación:

- Datos de producción en formato CSV (series temporales).
- Datos PVT (propiedades termodinámicas del fluido).
- Parámetros del reservorio en formato estructurado (por ejemplo, archivos TOML).

Estos datos son procesados por el backend —desarrollado en Python— que integra un modelo de machine learning previamente entrenado. El modelo es capaz de combinar información temporal, física y termodinámica para generar una estimación de la presión del reservorio.

En cuanto a la visualización, el frontend —desarrollado con TypeScript y React— presenta los resultados de manera interactiva y clara para el usuario. Se incluyen gráficos que permiten analizar la evolución de la presión estimada a lo largo del tiempo.

Asimismo, la interfaz incorpora componentes que facilitan la interpretación de los resultados, permitiendo identificar la influencia de las distintas variables de entrada en el comportamiento del modelo. De esta manera, no solo se muestra el valor estimado, sino que también se brinda contexto para su análisis y comprensión.

Además, la aplicación está diseñada con una arquitectura modular que separa claramente las responsabilidades en capas (dominio, infraestructura, repositorios, rutas), facilitando la mantenibilidad y escalabilidad del sistema.

10.1.2. Modelo de Machine Learning

El objetivo del modelo es predecir, a lo largo del tiempo, la presión promedio del reservorio a partir de datos operativos y de las propiedades del fluido.

Para este proyecto utilizamos un modelo de tipo LSTM (Long Short-Term Memory). Para la elección del mismo, se realizaron múltiples pruebas con distintos modelos: regresión lineal, random forests, XG-Boost y series de tiempo. Sin embargo, nos decantamos por LSTM ya que resultó ser el que generaliza de forma más robusta y pareja entre reservorios distintos.

En la sección 13 se detalla el procedimiento de entrenamiento y validación de cada modelo evaluado, junto con la comparación de resultados que motivó la elección del LSTM como modelo final.

Esquema de datos

El esquema de columnas del dataset fue propuesto por nuestros directores con un objetivo concreto: que el modelo tenga a disposición toda la información que aparece en la **ecuación de balance de masa**,

que es la ecuación física que gobierna la evolución de la presión del reservorio. La MBE relaciona la producción acumulada de fluidos, la inyección acumulada, las propiedades termodinámicas del fluido y la geometría del reservorio con el cambio de presión observado en el tiempo.

El dataset consta de dos tablas, cada tabla representa los datos de un reservorio en particular.

La primera (Tabla 1) tiene una fila por timestep e integra la petrofísica y la geometría del reservorio junto con los caudales de producción e inyección.

La segunda (Tabla 2) describe las propiedades termodinámicas del fluido medidas en laboratorio, tabuladas en función de la presión.

Nombre	Símbolo	Unidad	Tipo	Descripción
tiempo_dias	–	–	–	Tiempo en días desde el comienzo de la producción.
Porosidad	ϕ	fracción	Estática (Petrofísica)	Fracción de espacio vacío en la matriz rocosa.
Permeabilidad_mD	k	mD	Estática (Petrofísica)	Capacidad de la roca para permitir el flujo de fluidos.
Espesor_Neto_m	h	m	Estática (Geometría)	Espesor productivo neto de la formación.
Area	A	m ²	Estática (Geometría)	Área total de roca; multiplicada por h se obtiene el volumen total de roca.
Presion_Inicial_Reservorio_psi	P_{init}	psi	Estática (Condición inicial)	Presión promedio del reservorio antes de comenzar la producción.
Caudal_Prod_Petroleo_bbl	q_o	bbl/d	Dinámica (Operativa)	Volumen diario de petróleo extraído en superficie.
Caudal_Prod_Gas_Mpc	Q_g	Mpc/d	Dinámica (Operativa)	Volumen diario de gas producido.
Caudal_Iny_Agua_bbl	q_{inj}	bbl/d	Dinámica (Operativa)	Volumen diario de agua inyectada al reservorio.
Prod_Acumulada_Petroleo	N_p	bbl	Dinámica (Histórica)	Sumatoria histórica del volumen de petróleo extraído.
Prod_Acumulada_Gas	G_p	scf	Dinámica (Histórica)	Sumatoria histórica del volumen de gas extraído.
Prod_Acumulada_Agua	W_p	bbl	Dinámica (Histórica)	Sumatoria histórica del volumen de agua extraída.
Iny_Acumulada_Agua	W_{inj}	bbl	Dinámica (Histórica)	Sumatoria histórica del volumen de agua inyectada.

Tabla 1: Esquema de la tabla de producción e inyección.

Nombre	Símbolo	Unidad	Tipo	Descripción
p_grid_psi	P	psi	Termodinámica (PVT)	Presión a la cual se miden las propiedades termodinámicas.
Bo_rb_stb	B_o	rb/stb	Termodinámica (PVT)	Factor volumétrico del petróleo (relación fondo-superficie).
Bg_rb_scf	B_g	rb/scf	Termodinámica (PVT)	Factor volumétrico del gas (relación fondo-superficie).
Rs_scf_stb	R_s	scf/stb	Termodinámica (PVT)	Relación de gas disuelto por barril de petróleo.

Tabla 2: Esquema de la tabla PVT.

El **target** del modelo es la presión promedio del reservorio en cada timestep (P_r), una columna adicional del primer dataset que no se usa como input sino como variable a predecir.

Generación de datos sintéticos

Para entrenar el modelo LSTM utilizamos datos sintéticos. La razón principal es que conseguir datos reales con el esquema que necesitamos (presión del reservorio en función de variables operativas y propiedades del fluido, a lo largo del tiempo) es difícil sin una colaboración directa con una empresa petrolera, ya que se trata de información sensible que las operadoras manejan bajo confidencialidad.

Para generar los datos sintéticos utilizamos el simulador OPM Flow, junto con una herramienta que desarrollamos en Python para poder extraer los datos que necesitamos. El simulador OPM Flow toma como input un modelo de reservorio definido en el formato ECLIPSE, que contiene toda la descripción física del campo: la geometría del reservorio, las propiedades de la roca, la tabla PVT del fluido, la configuración de los pozos y el cronograma operativo de producción e inyección. A partir de esa entrada, OPM Flow simula el proceso productivo paso a paso en el tiempo y genera archivos con el historial completo del estado del reservorio, capturando variables como la presión, los caudales de producción e inyección, las saturaciones de cada fase y demás propiedades por celda.

En concreto, utilizamos dos modelos de reservorios que representan campos reales del Mar del Norte y del Mar de Noruega: **Norne** y **Volve**. Decidimos utilizar estos modelos ya que se trata de yacimientos genuinos que estuvieron en producción durante años, operados originalmente por la petrolera noruega Equinor. Además, son dos de los benchmarks más populares en la industria y la academia. La mayoría de los otros modelos públicos disponibles son reservorios teóricos inventados con fines académicos, sin correspondencia con un campo concreto.

Para otorgarle variabilidad al dataset, ejecutamos distintas simulaciones (30 simulaciones del modelo Norne, y 10 simulaciones del modelo Volve), variando ciertos parámetros del reservorio en cada una, de manera de obtener corridas con comportamientos distintos. Las variables que ajustamos fueron la porosidad de la roca, su permeabilidad, la presión inicial del reservorio y el esquema de inyección de

agua. Esto nos permitió obtener un dataset con suficiente diversidad de comportamientos, de modo que el modelo aprenda patrones generalizables en lugar de memorizar una única trayectoria de presión.

A continuación se incluyen visualizaciones de los datasets generados, mostrando variables como la presión, caudales de inyección y producción, en función del tiempo.




Figura 2: Caudal de inyección de agua (simulaciones Norne)




Figura 3: Caudal de inyección de agua (simulaciones Volve)




Figura 4: Producción acumulada de petróleo y agua (simulaciones Norne)




Figura 5: Producción acumulada de petróleo y agua (simulaciones Volve)




Figura 6: Presión en función del tiempo (simulaciones Norne)




Figura 7: Presión en función del tiempo (simulaciones Volve)

Normalización de datos y Feature Engineering

A partir del análisis exploratorio del dataset, encontramos que los reservorios de Volve y Norne operan en rangos muy distintos de presión, caudales de producción y volúmenes acumulados, lo cual era esperable dado que se trata de campos de tamaños muy diferentes (Norne es aproximadamente 6 veces mas grande que Volve). Esto nos llevó a aplicar varias normalizaciones a los datos antes de pasarlos al modelo.

La primera fue dividir las cantidades dependientes del tamaño del campo (producciones acumuladas,

caudales de producción e inyección) por el pore-volume del reservorio, que es el volumen total que podría llenarse con fluido. De esta forma el modelo ve fracciones del volumen recuperado en lugar de barriles absolutos, y Norne y Volve se vuelven comparables a pesar de las diferencias de escala.

La segunda fue normalizar la presión, es decir, en lugar de predecir el valor absoluto de la presión (que está en el orden de 3000 - 5000 psi), predecimos la diferencia respecto de la presión inicial del reservorio, dividida por una escala fija de 5000 psi. El resultado es un target chico y cercano a cero, más estable para entrenar la red neuronal y que elimina la dependencia con el punto de partida particular de cada corrida.

Además de aplicar normalizaciones, también creamos nuevas features (sugeridas por nuestros directores) a partir de relaciones entre las columnas originales del dataset:

- **Fracciones de fluido recuperado e inyectado:** producciones acumuladas de petróleo y agua e inyección acumulada de agua, divididas por el pore-volume del reservorio. Indican qué proporción del volumen total disponible ya fue extraída o repuesta mediante inyección.
- **Relación gas-petróleo acumulada:** cuánto gas se produjo por cada barril de petróleo hasta el momento.
- **Relación agua-petróleo instantánea:** cuántos barriles de agua se producen por cada barril de petróleo en ese instante. Es un indicador clásico del avance del frente de agua hacia los pozos productores.
- **Water cut acumulado:** porcentaje del total de líquidos producidos que es agua.
- **Voidage replacement ratio simplificado:** relación entre el volumen total inyectado y el volumen total producido. Indica si la inyección de agua compensa la extracción y si se está logrando mantener la presión del reservorio.

Un problema con el que nos encontramos fue cómo incluir la tabla PVT como input del modelo, dado que es una tabla separada del dataset principal y con una estructura distinta a la de la información temporal, ya que tiene una fila por nivel de presión (con los valores de B_o , B_g y R_s medidos en laboratorio para ese nivel) y no cambia en el tiempo. Lo resolvimos agregando un **encoder de PVT**, un módulo pequeño que se entrena junto con el resto del modelo y cuya función es comprimir toda la tabla PVT a un vector resumen compacto. Ese vector se le pasa al modelo principal como un dato adicional por simulación, de manera que la información termodinámica del fluido influya en la predicción sin opacar a las variables que cambian con el tiempo.

11 Metodología aplicada

Se deberá explicar cómo y en qué grado se cumplieron las pautas siguientes:

- Desarrollo incremental, por iteraciones o bajo una modalidad de entrega continua. Qué entregables intermedios hubo y cuál fue la cadencia de prácticas de seguimiento y mejora continua.
- Grado de automatización de las tareas de desarrollo, prueba y despliegue, con indicadores.
- Qué herramienta de versionado de código y de otros artefactos se utilizó.
- Qué herramienta se utilizó para gestionar el proceso de desarrollo, el seguimiento de tickets y bugs, etc.
- Qué artefactos se utilizaron para la gestión del alcance, riesgos, métricas de calidad del producto, criticidad de bugs, indicadores de tiempos y costos, minutas y otros artefactos de gestión de la comunicación con los interesados.
- Cuáles fueron los criterios de aceptación de entregas y pruebas de aceptación de las funcionalidades requeridas.
- Qué indicadores de calidad de proceso se utilizaron.

12 Herramientas externas utilizadas

Aplicación Web

Para el desarrollo de la aplicación web se utilizaron diversas herramientas y tecnologías, tanto para el backend como para el frontend y el despliegue del sistema:

- **FastAPI**: framework web en Python utilizado para la construcción de la API REST, permitiendo un desarrollo rápido y eficiente de endpoints.
- **NumPy y Pandas**: utilizadas para la manipulación y procesamiento de datos, especialmente en la carga y transformación de archivos CSV.
- **Alembic**: herramienta de migraciones de base de datos, utilizada para gestionar cambios en el esquema de la base de datos.
- **SQLAlchemy**: ORM utilizado para la interacción con la base de datos desde el backend.
- **JWT (JSON Web Tokens)**: utilizado para la autenticación y autorización de usuarios dentro del sistema.
- **React**: biblioteca de JavaScript utilizada para la construcción de la interfaz de usuario.
- **TypeScript**: lenguaje utilizado en el frontend para mejorar la calidad del código mediante tipado estático.
- **Vite**: herramienta de desarrollo utilizada para el bundling y ejecución del frontend.
- **Charting libraries (gráficos)**: utilizadas para la visualización de resultados, incluyendo gráficos de presión y análisis de variables.
- **Docker y Docker Compose**: utilizados para contenerizar la aplicación y facilitar su despliegue en diferentes entornos.
- **Git**: sistema de control de versiones utilizado para la gestión del código fuente.

Estas herramientas permitieron construir una solución robusta, escalable y mantenible, integrando tanto capacidades de procesamiento de datos como visualización e interacción con el usuario.

Modelo de Machine Learning

Para el desarrollo del modelo de machine learning se utilizaron distintas herramientas y librerías, tanto para el procesamiento de los datos como para el entrenamiento, evaluación y visualización de los resultados:

- **Python:** lenguaje principal utilizado para el entrenamiento y evaluación de los modelos, en conjunto con las siguientes librerías:
 - **PyTorch:** para el entrenamiento y evaluación del modelo LSTM.
 - **scikit-learn:** para el entrenamiento y evaluación de los modelos de regresión, random forest, y XGBoost.
 - **NumPy y Pandas:** utilizadas para la manipulación y procesamiento de los datasets en formato CSV.
 - **Matplotlib:** utilizada para crear visualizaciones, tanto para el análisis exploratorio como para los resultados de los distintos modelos.
 - **resdata:** librería de Python utilizada para parsear los archivos de salida de OPM Flow y generar el dataset sintético.
- **Google Colab:** entorno de ejecución utilizado para correr los notebooks de entrenamiento y evaluación.
- **Jupyter notebooks:** utilizados para ejecutar los notebooks de forma automatizada y reproducible.
- **OPM Flow:** simulador open source de flujo en medios porosos utilizado para generar el dataset sintético a partir de los modelos de reservorio en formato ECLIPSE.
- **Docker:** utilizado para correr OPM Flow en contenedores independientes y paralelizar la generación del dataset sin conflictos entre simulaciones concurrentes.

13 Experimentación y/o validación

Durante el entrenamiento de los modelos se realizaron múltiples pruebas para validar la efectividad de los mismos, compararlos, y decidir cuál utilizar en el proyecto:

Dado que contamos con dos modelos de reservorio (Norne y Volve), esto nos permitió validar que el modelo es capaz de generalizar entre reservorios distintos. En este contexto, realizamos dos tipos de pruebas:

- **Evaluación in-distribution:** el modelo se entrena con 24 de las 30 simulaciones de Norne y se evalúa sobre las 6 simulaciones restantes de Norne. Esto nos permite medir qué tan bien el modelo predice la presión del campo con el que fue entrenado.
- **Evaluación cross-reservoir:** el modelo se evalúa sobre las 10 simulaciones completas de Volve, un reservorio al que nunca fue expuesto durante el entrenamiento. Esto nos permite saber si el modelo aprendió la física subyacente o si solamente memorizó la distribución particular de Norne.

Para definir la calidad de los modelos, nos basamos en las siguientes métricas:

- **R² (coeficiente de determinación):** mide qué fracción de la varianza del target explica el modelo.
- **MAE (Mean Absolute Error):** el error promedio absoluto en la misma unidad física que la presión del reservorio (psi).

13.1 Evaluación y análisis comparativo de los modelos de machine learning

A continuación se presenta un análisis comparativo de todos los modelos que se probaron durante la fase de entrenamiento.

13.1.1. Modelo baseline

El primer modelo que probamos fue una regresión lineal con regularización Ridge sobre las features adimensionales del reservorio. Con este modelo no buscamos alcanzar buena performance, sino establecer una cota inferior empírica contra la cual comparar los modelos posteriores.

Split	R ²	MAE (psi)
Norne test (in-distribution)	0.959	35.23
Volve (cross-reservoir)	-891.83	8166.51

Tabla 3: Métricas del modelo baseline (regresión Ridge).




Figura 8: Comparación entre la presión real de Norne y la presión predicha por el modelo baseline




Figura 9: Parity plot entre la presión real de Norne vs. la presión predicha por el modelo baseline




Figura 10: Comparación entre la presión real de Volve y la presión predicha por el modelo baseline




Figura 11: Parity plot entre la presión real de Volve vs. la presión predicha por el modelo baseline

A partir de los valores del coeficiente de determinación (0.959 para Norne, -891.83 para Volve), se puede deducir que claramente el modelo overfittea para los datos de entrenamiento, y no logra extrapolar la predicción para reservorios con una distribución distinta a la de Norne.

13.1.2. Random Forest

Una vez realizadas las pruebas con un modelo baseline, procedimos a entrenar un modelo Random Forest, con el objetivo de capturar interacciones no lineales entre las features que la regresión lineal no podía representar.

Tabla 4: Métricas del modelo Random Forest.

Split	R ²	MAE (psi)
Norne test (in-distribution)	0.977	22.99
Volve (cross-reservoir)	-9.03	842.43




Figura 12: Comparación entre la presión real de Norne y la presión predicha por el modelo random forest




Figura 13: Parity plot entre la presión real de Norne vs. la presión predicha por el modelo random forest




Figura 14: Comparación entre la presión real de Volve y la presión predicha por el modelo random forest




Figura 15: Parity plot entre la presión real de Volve vs. la presión predicha por el modelo random forest

Random Forest presenta una mejora respecto al modelo baseline sobre Norne: el R^2 sube de 0.96 a 0.98 y el MAE baja de 35 a 23 psi. Sin embargo, el modelo no logra extrapolar estos resultados al reservorio Volve, el R^2 es de -9.03 y el MAE supera los 800 psi. Aunque las predicciones ya no son tan extremas como las del baseline lineal, la incapacidad de generalizar fuera de la distribución de entrenamiento se mantiene.

13.1.3. XGBoost

El siguiente modelo a evaluar es XGBoost, es un modelo de árboles un poco más complejo, que en general supera a Random Forest en problemas tabulares.

Tabla 5: Métricas del modelo XGBoost.

Split	R^2	MAE (psi)
Norne test (in-distribution)	0.986	19.80
Volve (cross-reservoir)	-9.93	864.89




Figura 16: Comparación entre la presión real de Norne y la presión predicha por el modelo XGBoost




Figura 17: Parity plot entre la presión real de Norne vs. la presión predicha por el modelo XGBoost




Figura 18: Comparación entre la presión real de Volve y la presión predicha por el modelo XGBoost




Figura 19: Parity plot entre la presión real de Volve vs. la presión predicha por el modelo XGBoost

XGBoost obtiene la mejor performance in-distribution sobre Norne de los modelos probados: $R^2 = 0.986$ y MAE de apenas 19.80 psi, valores muy superiores al baseline. Sin embargo, mantiene la misma incapacidad de generalizar entre reservorios: el R^2 sobre Volve es de -9.93 y el MAE de 865 psi.

13.1.4. LSTM

En vista de que los modelos lineales y de árboles no son capaces de aprender la física subyacente del problema, decidimos probar un modelo LSTM, que suele tener buen rendimiento sobre datos basados en series de tiempo.

Tabla 6: Métricas del modelo LSTM

Split	R ²	MAE (psi)
Norne test (in-distribution)	0.910	51.70
Volve (cross-reservoir)	0.735	101.90




Figura 20: Comparación entre la presión real de Norne y la presión predicha por el modelo LSTM




Figura 21: Parity plot entre la presión real de Norne vs. la presión predicha por el modelo LSTM




Figura 22: Comparación entre la presión real de Volve y la presión predicha por el modelo LSTM




Figura 23: Parity plot entre la presión real de Volve vs. la presión predicha por el modelo LSTM

A diferencia de los otros modelos, podemos ver que LSTM logra buenos resultados tanto para el reservorio Norne como para Volve, es decir, es capaz de generalizar la predicción entre reservorios distintos.

En Norne, el modelo alcanza un R^2 de 0.91 en el test in-distribution, un valor algo más bajo que XGBoost en su propio reservorio (0.99). Sin embargo, el resultado más interesante está en los resultados de las predicciones de Volve, ya que se consigue un R^2 de 0.735 con un MAE de 101.9 psi, mientras que los demás modelos, bajo este protocolo, se mantenían en valores de R^2 negativos sobre Volve.

El modelo LSTM logra generar predicciones que mantienen la forma general de la trayectoria de presión de cada simulación de Volve, en contraste con los modelos lineales y de árboles, que predicen valores muy fuera del rango físico real.

13.1.5. Comparación final entre modelos

Los gráficos 24 y 25 comparan visualmente las métricas de los cuatro modelos sobre los dos splits. Dado que todos fueron entrenados con el mismo protocolo (24 simulaciones de Norne como train, 6 como test, las 10 simulaciones de Volve como evaluación cross-reservoir), la comparación es directa.

El gráfico de MAE usa escala logarítmica porque el rango de errores cubre tres órdenes de magnitud entre el mejor caso (XGBoost en Norne, 19.8 psi) y el peor (Ridge en Volve, más de 8000 psi). En el gráfico de R^2 , el valor del baseline en Volve ($-891,83$) está truncado para no ofuscar al resto de la escala.




Figura 24: Comparación del MAE entre los cuatro modelos, en Norne (in-distribution) y Volve (cross-reservoir). Escala logarítmica en el eje vertical.




Figura 25: Comparación del R^2 entre los cuatro modelos.

A partir de los gráficos se ve con claridad lo que ya habíamos observado en los análisis individuales de cada modelo: bajo este protocolo, el LSTM es el que mejor generaliza al reservorio no visto. Los demás modelos alcanzan métricas muy buenas in-distribution sobre Norne pero colapsan al evaluar

sobre Volve, mientras que el LSTM mantiene un R^2 positivo y un MAE varios órdenes de magnitud menor en el split cross-reservoir.

Ahora bien, este colapso de los modelos lineales y de árboles sobre Volve depende fuertemente de la formulación del problema y no debe leerse como una incapacidad intrínseca de esas familias de modelo. En este experimento, el LSTM predice la diferencia de presión respecto de P_{init} (un objetivo anclado y transferible entre campos), mientras que los modelos restantes fueron entrenados para predecir la presión absoluta. Como se muestra en la sección 13.2, cuando los modelos de árboles reciben el mismo anclaje a P_{init} , también logran transferir a un campo no visto. En otras palabras, el factor determinante de la transferencia resulta ser el anclaje a P_{init} y la cobertura de dominio, más que la familia de modelo elegida.

13.2 Validación de generalización multi-campo (leave-one-field-out)

La comparación anterior entrena con un único campo (Norne) y evalúa la transferencia a un segundo campo (Volve). Para poner a prueba la generalización de forma más exigente, realizamos un segundo experimento que incorpora un tercer reservorio, **SPE9**, y adopta un protocolo de *leave-one-field-out*: para cada campo objetivo, el modelo se entrena con los otros dos campos completos y predice el campo que nunca vio.

Los tres campos utilizados son Volve (10 simulaciones), Norne (30) y SPE9 (100). Para que la comparación entre familias de modelo sea justa, los tres reciben exactamente la misma entrada: el mismo conjunto de features adimensionales (normalizadas por el pore-volume, sin lags del target y descartando B_o , B_g y R_s por su dependencia directa de la presión), y el mismo objetivo anclado a la presión inicial ($\Delta = P - P_{init}$, del que se reconstruye $P = P_{init} + \hat{\Delta}$). Anclar a P_{init} es lo que permite comparar campos con niveles de presión distintos: sin este anclaje, los tres modelos arrojan R^2 negativo en todos los campos.

Se comparan tres familias: Ridge (lineal regularizado), XGBoost (árboles con boosting) y LSTM (red recurrente). Cabe aclarar que el LSTM evaluado en este experimento es una versión genérica sobre las mismas features, que no incorpora el encoder de PVT descrito anteriormente; por lo tanto, sus métricas aquí constituyen una cota inferior de su rendimiento real.

Campo objetivo (R^2 zero-shot)	Ridge	XGBoost	LSTM
Volve	-0.68	+0.69	+0.53
Norne	+0.80	+0.23	+0.72
SPE9	+0.38	-1.21	-0.86
R^2 medio	+0.17	-0.10	+0.13
R^2 mediano por simulación	-0.16	-0.33	-0.05

Tabla 7: Generalización entre campos (leave-one-field-out). Cada fila es un campo no visto durante el entrenamiento. El R^2 mediano por simulación es más exigente: obliga a seguir la trayectoria de cada corrida, no sólo el nivel promedio del campo.

De este experimento se desprenden varias observaciones:

- **No hay un ganador único entre familias de modelo.** Cada modelo gana en un campo distinto: XGBoost transfiere mejor a Volve ($R^2 = 0,69$) y Ridge a Norne ($R^2 = 0,80$). A diferencia de lo observado en el experimento anterior, los modelos de árboles *sí* logran transferir a un campo no visto cuando reciben el target anclado a P_{init} .
- **El LSTM es el más robusto.** Es el único positivo en Volve y Norne a la vez y obtiene el mejor R^2 mediano por simulación; no se desploma como XGBoost en el campo más difícil. El costo es un entrenamiento sensiblemente más lento.
- **XGBoost es el más volátil.** Su mayor capacidad le da el mejor resultado en Volve pero el peor en SPE9 ($-1,21$): cuando el campo nuevo es muy distinto, sobreajusta y extrapola mal.
- **Ningún modelo resuelve SPE9.** Es el campo más distinto de los tres —su presión cruza el punto de burbuja y libera gas, un régimen ausente en el entrenamiento— y los tres modelos dan un R^2 pobre o negativo. El $+0,38$ de Ridge es engañoso: su R^2 por simulación es prácticamente nulo, es decir, acierta el nivel promedio entre simulaciones pero no la trayectoria real.

La conclusión central de este experimento es que el factor que determina la transferencia no es tanto la familia de modelo (Ridge vs. XGBoost vs. LSTM) sino dos elementos metodológicos: **anclar la predicción a P_{init}** y **contar con cobertura de dominio**, esto es, que el entrenamiento incluya algún campo parecido al campo objetivo. Los modelos transfieren bien cuando el campo nuevo se asemeja a los de entrenamiento (Volve, Norne) y fallan cuando pertenece a un régimen que nunca vieron (SPE9, que cruza el punto de burbuja).

14 Cronograma de las actividades realizadas

El desarrollo del proyecto se llevó a cabo en dos cuatrimestres, cada uno con objetivos y actividades específicas:

Primer cuatrimestre (18/08/2025 – 01/12/2025):

- Estudio del dominio de la ingeniería de reservorios.
- Lectura y análisis de bibliografía especializada: Reservoir Engineering Handbook, fourth edition.
- Identificación de variables relevantes y comprensión de sus relaciones.
- Elaboración y entrega del informe intermedio.

Segundo cuatrimestre (09/03/2026 – 10/03/2026):

- Generación inicial de datos sintéticos mediante LLMs.
- Análisis exploratorio de los datos generados.
- Exploración de librerías de generación de datos sintéticos (SDV, YData Synthetic, Gretel, etc.).
- Validación y discusión de resultados con la experta en dominio.
- Evaluación de alternativas para la generación de datos más realistas.
- Adopción de OPM Flow como herramienta de simulación.
- Selección de datos correspondientes a los reservorios Norne y Volve.
- Análisis exploratorio de los nuevos datos.
- Entrenamiento y evaluación de modelos de machine learning:
 - Modelo baseline (Ridge).
 - Random Forest.
 - XGBoost.
 - LSTM con integración de datos PVT.
 - Comparación de resultados y selección del modelo final.
- Evaluación de tecnologías para el desarrollo de la aplicación web.
- Diseño de la arquitectura de la aplicación y definición de endpoints.

- Implementación de la API REST para la predicción de presión.
- Implementación de la interfaz de usuario para la visualización de resultados.
- Integración del modelo con la aplicación.
- Visualización de resultados y validación final.
- Elaboración del informe final y entrega del proyecto.

15 Riesgos materializados y Lecciones aprendidas

15.1 Riesgos materializados

15.1.1. Dependencia de datos de la industria

Uno de los principales riesgos fue la dependencia de datos provenientes de la industria y la escasez de datos reales de presión. Este riesgo se materializó durante el primer cuatrimestre y se mantuvo durante el segundo cuatrimestre.

El equipo esperaba contar con datos provistos por PAE, sin embargo, debido a que el trabajo debía ser de carácter público, no fue posible acceder a dichos datos.

Esta situación implicó un período prolongado de espera e incertidumbre, lo que impactó directamente en la planificación inicial y retrasó el avance del proyecto, particularmente en las etapas de experimentación y modelado.

Se analizaron fuentes de datos públicas, como la información disponible en el Capítulo IV de la Secretaría de Energía de la República Argentina. No obstante, estas fuentes no incluyen datos de presión de reservorios, lo que limitó su utilidad para el problema abordado y reforzó la dependencia de datos privados de la industria.

Como consecuencia, fue necesario redefinir la estrategia de trabajo y optar inicialmente por el uso de datos sintéticos.

Durante el segundo cuatrimestre, se intentó generar estos datos mediante distintas herramientas, pero la falta de confianza en su realismo motivó la adopción de un enfoque alternativo basado en simulaciones físicas utilizando OPM Flow, lo que permitió obtener datasets más representativos.

15.2 Lecciones aprendidas

15.2.1. Comprensión del dominio

En cuanto a las lecciones aprendidas, se destaca en primer lugar la importancia de comprender profundamente el dominio del problema antes de abordar el modelado. El estudio realizado en la primera etapa resultó fundamental para identificar las variables relevantes y orientar correctamente el análisis de datos y la construcción de modelos.

15.2.2. Flexibilidad y adaptabilidad

Asimismo, se evidenció que la planificación de proyectos en contextos reales debe contemplar la incertidumbre asociada al acceso y calidad de los datos. La necesidad de adaptar la estrategia de generación y selección de datos puso de manifiesto la importancia de mantener un enfoque flexible e iterativo.

15.2.3. Importancia de la validación continua

Finalmente, se aprendió que la validación continua con expertos en el dominio es clave para garantizar la calidad y relevancia de los resultados, especialmente en problemas interdisciplinarios donde el conocimiento técnico por sí solo no es suficiente.

16 Impactos sociales y ambientales del proyecto

Actualizar esto:

Una estimación precisa de la presión de yacimiento es indispensable en la producción de hidrocarburos, ya que define un estrecho “margen de presión” operativo que es fundamental para la seguridad, la eficiencia y la rentabilidad.

En este contexto, la solución propuesta puede tener impacto en distintos aspectos de la industria:

16.1 Impacto económico

- **Optimización de la producción:** permite una mejor planificación de las estrategias de extracción y selección de métodos de recuperación adecuados, reduciendo costos operativos.

16.2 Impacto social y ambiental

- **Reducción de riesgos:** una correcta estimación de la presión puede evitar consecuencias catastróficas como la pérdida de equipos, daños medioambientales e incluso la pérdida de vidas humanas.

17 Trabajos futuros

Texto (sección opcional).

18 Conclusiones

Texto.

19 Aportes individuales

20 Referencias

Referencias

- [1] Barriol, Y. (2005). *Las presiones de las operaciones de perforación y producción*. Oil-field Review, 22. <https://usuarios.geofisica.unam.mx/gvazquez/geoquimpetrolFI/zonadesplegar/Lecturas/Las%20presiones%20de%20las%20operaciones%20%20de%20perforacion%20y%20producc.pdf>
- [2] Maarouf, A., Tahir, S., Su, S., Kloucha, C. K., & Mustapha, H. (2023). *A comparative study for deep-learning-based methods for automated reservoir simulation*. SPE Reservoir Characterisation and Simulation Conference and Exhibition. https://www.researchgate.net/publication/367379296_A_Comparative_Study_for_Deep-Learning-Based-Methods_for_Automated_Reservoir_Simulation
- [3] Chen, X., Zhang, K., Ji, Z., Shen, X., Liu, P., Zhang, L., Wang, J., & Yao, J. (2023). *Progress and Challenges of Integrated Machine Learning and Traditional Numerical Algorithms: Taking Reservoir Numerical Simulation as an Example*. Mathematics, 11(21), 4418. <https://www.mdpi.com/2227-7390/11/21/4418>
- [4] El Hannaoui, M. (2025). *Artificial Intelligence in Oil and Gas: How AI is Transforming Reservoir Engineering*. Novi Labs. <https://novilabs.com/blog/ai-in-reservoir-engineering-how-artificial-intelligence-is-transforming-oil-gas/>
- [5] Ali, A. (2021). *Machine learning based data-driven methods for modelling and simulation of pressure dynamics and fluid flow in natural gas reservoirs* (Tesis doctoral, University of Sheffield). https://etheses.whiterose.ac.uk/id/eprint/29161/1/Aliyuda_Final_Thesis.pdf
- [6] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-Informed Neural Networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 378, 686-707. <https://www.sciencedirect.com/science/article/abs/pii/S0021999118307125>

21 Anexos

Contenido de los anexos.