

Universidad de Buenos Aires
Facultad de Ingeniería

Data Analytics para la estimación de la presión de yacimientos de petróleo

Tutor: Dr. Hernán Merlino

Co-tutor: Dra. Gabriela Savioli

Integrantes

Alan Valdevenito	107585	avaldevenito@fi.uba.ar
Franco Bragantini	97190	fbragantini@fi.uba.ar
Mateo Rico	108127	mrico@fi.uba.ar
Máximo Palopoli	108755	mpalopoli@fi.uba.ar

Índice

1. Aval del Director	1
2. Resumen	2
3. Palabras clave	2
4. Abstract	3
5. Keywords	3
6. Agradecimientos	4
7. Introducción	5
8. Estado del Arte	5
9. Problema detectado y/o faltante	7
10. Solución implementada	8
10.1. Arquitectura	8
10.1.1. Modelo de Machine Learning	8
10.1.2. Aplicación Web	8
11. Metodología aplicada	9
12. Herramientas externas utilizadas	10
13. Experimentación y/o validación	11
14. Cronograma de las actividades realizadas	11
15. Riesgos materializados y Lecciones aprendidas	11
16. Impactos sociales y ambientales del proyecto	11
16.1. Impacto económico	11
16.2. Impacto social y ambiental	11
17. Trabajos futuros	11
18. Conclusiones	11

19. Aportes individuales	11
20. Referencias	12
21. Anexos	13

1 Aval del Director

Por la presente, dejo constancia de que el trabajo final titulado “*Data Analytics para la estimación de la presión de yacimientos de petróleo*”, realizado por los integrantes Bragantini, Palopoli, Rico y Valdevenito, ha sido desarrollado bajo mi dirección y cuenta con mi aval para su presentación y defensa.

Firma del Director

Nombre del Director

2 Resumen

La estimación precisa de la presión en yacimientos de petróleo es un factor crítico para la gestión eficiente de la producción de hidrocarburos. Los métodos tradicionales, basados en la física de reservorios, presentan limitaciones frente al creciente volumen y complejidad de los datos disponibles. En este contexto, surge la necesidad de explorar nuevas herramientas que permitan realizar predicciones rápidas, robustas y escalables.

Este proyecto propone el desarrollo de un sistema basado en técnicas de *Data Analytics* y *Machine Learning*, orientado a la estimación de la presión de yacimientos. La solución integra un módulo de predicción que consume y procesa datos físicos del reservorio, entrenando modelos de regresión y aprendizaje profundo, junto con una interfaz web que facilita su uso por parte de ingenieros sin formación específica en ciencia de datos.

La metodología incluye el preprocesamiento y limpieza de datos, el diseño de *features*, la comparación de distintos algoritmos (como Random Forest, XGBoost, LSTM y PINNs) y la validación mediante métricas estándar de regresión, pruebas cruzadas y contrastes con metodologías convencionales (PTA, EBM). Asimismo, el proyecto sigue un enfoque ágil, con entregables iterativos y validación continua para garantizar la utilidad y confiabilidad del sistema.

El impacto esperado de esta propuesta radica en la optimización de la producción, la reducción de riesgos operativos y ambientales, y la provisión de una herramienta transparente y escalable que contribuya a la toma de decisiones en la industria energética.

3 Palabras clave

Yacimiento de petróleo, machine learning, estimación de presión, física de reservorio, recuperación secundaria.

4 Abstract

Accurate estimation of reservoir pressure is a key factor in the efficient management of hydrocarbon production. Traditional methods, based on reservoir physics, present limitations when dealing with the increasing volume and complexity of modern data. In this context, new approaches are required to provide fast, robust, and scalable predictions.

This project proposes the development of a system based on *Data Analytics* and *Machine Learning* techniques for reservoir pressure estimation. The solution integrates a prediction module that processes reservoir data and trains regression and deep learning models, along with a web interface designed for engineers without data science expertise.

The methodology includes data preprocessing and cleaning, feature engineering, evaluation of various algorithms (such as Random Forest, XGBoost, LSTM, and PINNs), and validation through standard regression metrics, cross-validation, and comparisons with conventional methods (PTA, EBM). The project follows an agile approach with iterative deliverables and continuous validation to ensure the system's utility and reliability.

The expected impact lies in production optimization, reduction of operational and environmental risks, and the delivery of a transparent and scalable tool that supports decision-making in the energy industry.

5 Keywords

Oil reservoir, machine learning, pressure estimation, reservoir physics, secondary recovery.

6 Agradecimientos

Texto de agradecimientos (sección opcional).

7 Introducción

La extracción de petróleo es un proceso que se lleva a cabo en formaciones subterráneas conocidas como yacimientos, donde el hidrocarburo, junto con otras sustancias como gas y agua, se encuentra almacenado en rocas porosas bajo condiciones de presión natural.

La gestión eficaz y la explotación económica de dichos yacimientos dependen fundamentalmente de una comprensión precisa de sus propiedades y comportamientos. Entre todos los parámetros que gobiernan la producción de hidrocarburos, la **presión** de yacimiento se erige como la variable más crítica.

Durante la fase inicial de la producción (recuperación primaria), la presión del reservorio es la fuerza motriz que empuja los fluidos desde la roca hasta la superficie [1]. Sin embargo, a medida que avanza la explotación del yacimiento, la presión disminuye progresivamente, por lo que para sostener la producción es necesario mantener o incrementar la presión mediante diferentes técnicas, entre las que destacan los métodos de **recuperación secundaria**, como la inyección de agua o gas.

En este contexto, la correcta estimación de la presión es la piedra angular de la ingeniería de yacimientos moderna, influyendo en cada decisión, desde la perforación del primer pozo exploratorio hasta el abandono final del campo.

Proponemos implementar un modelo predictivo que combine la física del reservorio con técnicas de data analytics, para poder estimar la presión de los yacimientos de hidrocarburos.

En las siguientes secciones se describe en mayor detalle el problema a resolver, la solución propuesta, el impacto del proyecto en la industria, la planificación del desarrollo, la metodología a seguir y los mecanismos de validación del sistema.

8 Estado del Arte

Antes de la llegada del análisis de datos a gran escala, la ingeniería de yacimientos se basaba en dos pilares metodológicos: el Análisis de Transientes de Presión (PTA por sus siglas en inglés) y la Ecuación de Balance de Materiales (EBM).

El PTA es un enfoque dinámico que analiza la respuesta de la presión ante perturbaciones en el pozo. Incluye pruebas como drawdown y buildup, que permiten calcular parámetros locales como la permeabilidad promedio, el factor de daño (skin) y la presión promedio del área de drenaje. Su fortaleza radica en la alta resolución cerca del pozo, aunque con alcance espacial limitado.

La EBM, por su parte, aplica la conservación de la masa tratando al yacimiento como un “tanque” a volumen constante. Facilita la estimación de POES/GOES, la identificación del mecanismo de empuje y la predicción del comportamiento futuro. Su análisis suele apoyarse en métodos gráficos como P/Z vs. G_p , aunque asume homogeneidad en el yacimiento.

Ambos enfoques físicos, basados en los principios fundamentales de la física de fluidos en medios porosos, son complementarios y representan las herramientas clásicas que han permitido la caracterización y gestión de yacimientos durante décadas.

En la actualidad, la industria vive una transición hacia el paradigma basado en datos [5], impulsada por el crecimiento del volumen de datos proveniente de fuentes como adquisición sísmica, registros de perforación, sensores permanentes de pozos y laboratorios. El desafío ya no es la adquisición de datos, sino su integración, normalización e interpretación efectiva. La información a menudo reside en silos, en formatos dispares y con calidades variables, lo que dificulta la creación de una visión unificada y coherente del yacimiento.

En este contexto, los métodos de data analytics y machine learning se posicionan como herramientas capaces de aprender directamente de los datos históricos. Estos modelos permiten:

- Optimizar la producción, identificando patrones ocultos y anticipando problemas como la irrupción de agua o arena.
- Mejorar la caracterización de yacimientos, integrando múltiples fuentes para generar modelos más precisos (ejemplo: incrementos del 30 % en la precisión de modelos geológicos reportados en la industria).
- Habilitar el mantenimiento predictivo, anticipando fallos en equipos críticos mediante análisis de datos de sensores.
- Reducir costos y riesgos, al mejorar la toma de decisiones en tiempo real y aumentar la seguridad operacional.

Entre los algoritmos más destacados se encuentran:

- **Redes Neuronales Artificiales (ANN):** sobresalientes en mapeos complejos, con resultados que superan correlaciones empíricas.
- **Random Forest y XGBoost:** robustos y eficientes para predicción de presiones críticas (p. ej., presión de burbuja, presión de poro).
- **Support Vector Regression (SVR):** eficaz en espacios de alta dimensionalidad, mejorando su precisión mediante optimización de hiperparámetros.
- **Redes LSTM:** especialistas en series temporales, ideales para pronósticos de producción y presión.

El avance más reciente es la integración de datos y física en enfoques híbridos. Los proxies de ML permiten generar predicciones en milisegundos tras ser entrenados con simulaciones numéricas, y las Redes Neuronales Informadas por la Física (PINNs) [6] incorporan ecuaciones diferenciales en su entrenamiento, garantizando consistencia física aun en ausencia de datos. Esto transforma el machine learning desde una “caja negra” hacia una verdadera herramienta de computación científica.

9 Problema detectado y/o faltante

Los métodos convencionales, aunque robustos y basados en principios físicos sólidos, muestran limitaciones significativas para manejar la escala y complejidad de los datos modernos:

- **Costo computacional:** La simulación numérica de yacimientos, el estándar de oro para el modelado predictivo, es un proceso extremadamente intensivo en términos computacionales. Una sola simulación de un modelo de alta resolución puede tardar horas o incluso días en completarse, lo que hace inviable la exploración exhaustiva de incertidumbres o la optimización en tiempo real [2].
- **Simplificación excesiva:** Los modelos analíticos, como la EBM, deben hacer suposiciones simplificadoras (por ejemplo, tratar el yacimiento como un tanque homogéneo) para ser matemáticamente tratables. Esto puede pasar por alto la heterogeneidad espacial compleja que a menudo controla el flujo de fluidos en la realidad [3].
- **Análisis manual y lento:** La interpretación de pruebas de pozo o la calibración de un simulador (ajuste histórico) son procesos que tradicionalmente han requerido un esfuerzo manual significativo por parte de ingenieros expertos, lo que los convierte en procesos lentos y potencialmente subjetivos [4].

En consecuencia, existe una brecha entre las necesidades actuales —predicciones rápidas, robustas y capaces de integrar múltiples fuentes de datos— y las capacidades de las metodologías tradicionales.

Esta brecha justifica la **exploración de nuevos enfoques** basados en Machine Learning, que permitan aprovechar datos históricos para generar estimaciones de presión más ágiles, transparentes y escalables.

10 Solución implementada

La solución implementada es una aplicación web que realizar estimaciones de la presión de un reservorio mediante un modelo de machine learning. El sistema toma como entrada un conjunto de datos cargados por el usuario y, a partir de ellos, genera una predicción de la presión del reservorio.

La información requerida comprende datos de producción, que corresponden a series temporales registradas a lo largo de la vida del reservorio, datos físicos del reservorio, e información termodinámica del petróleo del reservorio.

Una vez cargados los datos, el modelo procesa estas distintas fuentes de información para producir la estimación de presión. La aplicación presenta los resultados de forma visual, mediante gráficos que muestran tanto la presión estimada como la incertidumbre asociada a dicha estimación, permitiendo al usuario interpretar no solo el valor predicho sino también el grado de confianza del modelo.

10.1 Arquitectura

El sistema está compuesto una aplicación web (frontend y backend) y un modelo de machine learning.




Figura 1: Diagrama de arquitectura del sistema

En las siguientes secciones se detalla cada componente en profundidad.

10.1.1. Modelo de Machine Learning

10.1.2. Aplicación Web

El sistema está compuesto por una arquitectura cliente-servidor, donde el frontend permite la interacción con el usuario y el backend se encarga del procesamiento de datos, autenticación y ejecución del modelo predictivo.

La aplicación permite a los usuarios registrarse e iniciar sesión, gestionando el acceso a las funcionalidades mediante autenticación. Una vez dentro del sistema, el usuario puede cargar diferentes tipos de datos necesarios para la estimación:

- Datos de producción en formato CSV (series temporales).
- Datos PVT (propiedades termodinámicas del fluido).
- Parámetros del reservorio en formato estructurado (por ejemplo, archivos TOML).

Estos datos son procesados por el backend —desarrollado en Python— que integra un modelo de machine learning previamente entrenado. El modelo es capaz de combinar información temporal, física y termodinámica para generar una estimación de la presión del reservorio.

En cuanto a la visualización, el frontend —desarrollado con TypeScript y React— presenta los resultados de manera interactiva y clara para el usuario. Se incluyen gráficos que permiten analizar la evolución de la presión estimada a lo largo del tiempo.

Asimismo, la interfaz incorpora componentes que facilitan la interpretación de los resultados, permitiendo identificar la influencia de las distintas variables de entrada en el comportamiento del modelo. De esta manera, no solo se muestra el valor estimado, sino que también se brinda contexto para su análisis y comprensión.

Además, la aplicación está diseñada con una arquitectura modular que separa claramente las responsabilidades en capas (dominio, infraestructura, repositorios, rutas), facilitando la mantenibilidad y escalabilidad del sistema.

11 Metodología aplicada

Se deberá explicar cómo y en qué grado se cumplieron las pautas siguientes:

- Desarrollo incremental, por iteraciones o bajo una modalidad de entrega continua. Qué entregables intermedios hubo y cuál fue la cadencia de prácticas de seguimiento y mejora continua.
- Grado de automatización de las tareas de desarrollo, prueba y despliegue, con indicadores.
- Qué herramienta de versionado de código y de otros artefactos se utilizó.
- Qué herramienta se utilizó para gestionar el proceso de desarrollo, el seguimiento de tickets y bugs, etc.
- Qué artefactos se utilizaron para la gestión del alcance, riesgos, métricas de calidad del producto, criticidad de bugs, indicadores de tiempos y costos, minutas y otros artefactos de gestión de la comunicación con los interesados.

- Cuáles fueron los criterios de aceptación de entregas y pruebas de aceptación de las funcionalidades requeridas.
- Qué indicadores de calidad de proceso se utilizaron.

12 Herramientas externas utilizadas

Modelo de Machine Learning

Aplicación Web

Para el desarrollo de la aplicación web se utilizaron diversas herramientas y tecnologías, tanto para el backend como para el frontend y el despliegue del sistema:

- **FastAPI**: framework web en Python utilizado para la construcción de la API REST, permitiendo un desarrollo rápido y eficiente de endpoints.
- **PyTorch**: biblioteca de machine learning empleada para la definición, entrenamiento y ejecución del modelo predictivo de presión.
- **NumPy y Pandas**: utilizadas para la manipulación y procesamiento de datos, especialmente en la carga y transformación de archivos CSV.
- **Alembic**: herramienta de migraciones de base de datos, utilizada para gestionar cambios en el esquema de la base de datos.
- **SQLAlchemy**: ORM utilizado para la interacción con la base de datos desde el backend.
- **JWT (JSON Web Tokens)**: utilizado para la autenticación y autorización de usuarios dentro del sistema.
- **React**: biblioteca de JavaScript utilizada para la construcción de la interfaz de usuario.
- **TypeScript**: lenguaje utilizado en el frontend para mejorar la calidad del código mediante tipado estático.
- **Vite**: herramienta de desarrollo utilizada para el bundling y ejecución del frontend.
- **Charting libraries (gráficos)**: utilizadas para la visualización de resultados, incluyendo gráficos de presión y análisis de variables.
- **Docker y Docker Compose**: utilizados para contenerizar la aplicación y facilitar su despliegue en diferentes entornos.

- **Git:** sistema de control de versiones utilizado para la gestión del código fuente.

Estas herramientas permitieron construir una solución robusta, escalable y mantenible, integrando tanto capacidades de procesamiento de datos como visualización e interacción con el usuario.

13 Experimentación y/o validación

14 Cronograma de las actividades realizadas

Texto.

15 Riesgos materializados y Lecciones aprendidas

Texto.

16 Impactos sociales y ambientales del proyecto

Actualizar esto:

Una estimación precisa de la presión de yacimiento es indispensable en la producción de hidrocarburos, ya que define un estrecho “margen de presión” operativo que es fundamental para la seguridad, la eficiencia y la rentabilidad.

En este contexto, la solución propuesta puede tener impacto en distintos aspectos de la industria:

16.1 Impacto económico

- **Optimización de la producción:** permite una mejor planificación de las estrategias de extracción y selección de métodos de recuperación adecuados, reduciendo costos operativos.

16.2 Impacto social y ambiental

- **Reducción de riesgos:** una correcta estimación de la presión puede evitar consecuencias catastróficas como la pérdida de equipos, daños medioambientales e incluso la pérdida de vidas humanas.

17 Trabajos futuros

Texto (sección opcional).

18 Conclusiones

Texto.

19 Aportes individuales

20 Referencias

Referencias

- [1] Barriol, Y. (2005). *Las presiones de las operaciones de perforación y producción*. Oil-field Review, 22. <https://usuarios.geofisica.unam.mx/gvazquez/geoquimpetrolFI/zonadesplegar/Lecturas/Las%20presiones%20de%20las%20operaciones%20%20de%20perforacion%20y%20producc.pdf>
- [2] Maarouf, A., Tahir, S., Su, S., Kloucha, C. K., & Mustapha, H. (2023). *A comparative study for deep-learning-based methods for automated reservoir simulation*. SPE Reservoir Characterisation and Simulation Conference and Exhibition. https://www.researchgate.net/publication/367379296_A_Comparative_Study_for_Deep-Learning-Based-Methods_for_Automated_Reservoir_Simulation
- [3] Chen, X., Zhang, K., Ji, Z., Shen, X., Liu, P., Zhang, L., Wang, J., & Yao, J. (2023). *Progress and Challenges of Integrated Machine Learning and Traditional Numerical Algorithms: Taking Reservoir Numerical Simulation as an Example*. Mathematics, 11(21), 4418. <https://www.mdpi.com/2227-7390/11/21/4418>
- [4] El Hannaoui, M. (2025). *Artificial Intelligence in Oil and Gas: How AI is Transforming Reservoir Engineering*. Novi Labs. <https://novilabs.com/blog/ai-in-reservoir-engineering-how-artificial-intelligence-is-transforming-oil-gas/>
- [5] Ali, A. (2021). *Machine learning based data-driven methods for modelling and simulation of pressure dynamics and fluid flow in natural gas reservoirs* (Tesis doctoral, University of Sheffield). https://etheses.whiterose.ac.uk/id/eprint/29161/1/Aliyuda_Final_Thesis.pdf
- [6] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-Informed Neural Networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 378, 686-707. <https://www.sciencedirect.com/science/article/abs/pii/S0021999118307125>

21 Anexos

Contenido de los anexos.